



Práctica DOI

Trabajo realizado por grupo 8.

1. Introducción

El objetivo de este trabajo es desarrollar una ontología OWL usando la metodología LOT y siguiendo los principios FAIR, desarrollar los shapes de SHACL para validar que los datos se adecúan a las restricciones del esquema y por último crear el grafo de conocimiento siguiendo la ontología con nuestro datos que conformarán nuestras instancias.

Para esto partimos de dos conjuntos de datos. El primer conjunto de datos hace referencia a los nominados de los premios Oscar (`oscar_awards.csv`) y el segundo a las características demográficas de los mismos (`oscar_demographics.csv`). Ambos datasets se han limpiado e integrado en un dataset único con los 20 elementos de nuestra ontología (`oscars.csv`). Los casos de uso que se plantean son los siguientes:

1. Consultar ganadores de Premios Óscar por categoría y año.
2. Analizar qué personas tuvieron más nominaciones y las características de las películas por las que fueron nominadas.
3. Cruzar datos de los oscars con los de otros datasets como los de IMDb.

2. Desarrollo


2.1 Requerimientos de la ontología.

Los requerimientos completos se encuentran en el documento “`OntologyRequirements.csv`”. Algunos de los requerimientos son los siguientes:

- ¿Quién ganó el premio de Mejor Actor en el primer evento?
- ¿Qué categorías había en la edición 59?
- ¿Quiénes son todos los nominados históricamente para la categoría “Best Picture”?
- ¿Cuántas nominaciones tuvo Titanic?

2.2 Decisiones de diseño de la ontología.

El desarrollo de la ontología se basó en los requerimientos identificados en el ORSD. El objetivo era modelar las características sociales y cinematográficas de los nominados a los Premios Oscar en distintas categorías.



La ontología se divide en 6 conceptos principales que podemos reunir en dos grupos. El primer grupo corresponde a la ceremonia y son los conceptos de Nomination, Category y Event. Algo a destacar es que usamos una relación *skos:narrower* para modelar la relación de más generalidad de Category sobre Nomination. Por ejemplo, Category podría ser instanciada como “Acting” y Nomination como “Best Actor”.

En el segundo grupo se juntan tres conceptos: Person, Character y Movie. Estos se relacionan de forma que una persona actúa como un personaje y el personaje aparece en una película. También por sugerencia de feedbacks anteriores el concepto Person lo hemos relacionado con tres Objecttype Properties que hacen referencia a características sociales como lo son Race, Religion y SexualOrientation.

Cada concepto tiene Datatype Properties que corresponden a las columnas de “oscars.csv”.

Además se han añadido los prefijos de los vocabularios que se han reutilizado y metadatos acerca de la ontología. Los vocabularios reusados se detallan en el siguiente apartado.

2.3 Recursos reusados de la ontología.

De acuerdo a los principios FAIR, concretamente al principio de interoperabilidad y reusabilidad se ha intentado reutilizar recursos de otras ontologías disponibles en la web siempre que ha sido posible y cuando no se han introducido los propios. Para ello se ha hecho uso del buscador LOV con tal de encontrar entidades de ontologías que pudiéramos incorporar en la nuestra. En nuestra ontología hemos hecho uso de tres vocabularios:

- **Schema.org** es un vocabulario para conceptos de alto nivel. Lo hemos usado para la entidad movie (schema:Movie) y la entidad event (schema:Event).
- **FOAF** es un vocabulario para describir personas y relaciones sociales. Lo hemos usado para la entidad person (foaf:Person).
- **DBpedia Ontology** es un vocabulario basado en las entidades de Wikipedia. Lo hemos usado para la entidad race (dbo:Race), la entidad religion (dbo:Religion) y la entidad sexual orientation (dbo:SexualOrientation).

2.4 Técnicas de evaluación y correcciones a la ontología.

De acuerdo con las recomendaciones y pasos a seguir propuestos se ha evaluado la ontología con la herramienta OOPS! en una primera instancia con el objetivo de comprobar los posibles fallos de diseño de la misma.

El resultado en un principio fue el siguiente:

Pitfalls detected:		
Results for P08: Missing annotations.	42 cases	Minor
Results for P10: Missing disjointness.	Ontology*	Important
Results for P11: Missing domain or range in properties.	19 cases	Important
Results for P13: Inverse relationships not explicitly declared.	12 cases	Minor
Results for P41: No license declared.	Ontology*	Important

En él podemos observar varios fallos importantes a corregir, así que utilizando los apuntes, ayuda de búsquedas online e IA (Claude) se fueron solventando los errores (se añadió la licencia de Creative Commons, se ajustaron las disyunciones que existían entre los campos y se estableció el dominio y rango de cada una de las propiedades) . En el momento de la entrega el análisis de OOPS! es el que se muestra a continuación:

Pitfalls detected:		
Results for P08: Missing annotations.	42 cases	Minor
Results for P13: Inverse relationships not explicitly declared.	12 cases	Minor

Se ha decidido dejar el Pitfall 13 como no resuelto ya que la alternativa a su arreglo era añadir todas las propiedades que fueran inversas, modificando el esquema inicial de la ontología en muchos puntos. Sobre el Pitfall 08 la decisión ha sido que aunque sí sería positivo para que la ontología fuera más accesible y el FAIRness level fuera mejor, se ha considerado que no era un punto determinante para el funcionamiento como tal de la ontología.

2.5 Sistema de documentación y licencia.

Widoco

Para utilizar Widoco se han realizado los siguientes pasos:

1. Accedemos al repositorio <https://github.com/dgarijo/Widoco/releases>
2. Nos descargamos tanto el código como el jar que queramos.
3. Es importante tener instalado java, en este caso hemos utilizado la versión "17.0.19" (winget install EclipseAdoptium.Temurin.17.JDK)
4. Para abrir widoco, usamos el comando `java -jar` y arrastramos el jar a la ventana de la terminal para que complete el comando.


The screenshot shows the 'Step 1: Select a template' window of Widoco. It features the Widoco logo and a list of steps: 1. Select template, 2. Load metadata, 3. Load sections, and 4. Finish. The first step is selected. There are three radio button options: 'Create template documentation from ontology file' (selected), 'Create template documentation from ontology URI', and 'Create empty skeleton'. Below these are input fields for 'document Path' and 'Insert here the URL of the vocabulary'. At the bottom, there are fields for 'Project name' (containing 'myDocumentation') and 'Project export location' (containing 'C:\WINDOWS\system32\myDocumentation'), with a 'Browse' button next to the latter. 'Next >' and 'Cancel' buttons are at the bottom right.

5. Se abrirá esta ventana. Utilizamos la opción marcada en la imagen y ponemos la ruta del archivo ttl de la ontología. En project name ponemos el nombre con el que queremos crear el archivo, en nuestro caso OscarsOntologyDoc y en project export location indicamos la dirección donde queremos crear la carpeta. Importante que no sea System32.

The screenshot shows the 'Step 2: Load the metadata' window of Widoco. It features the Widoco logo and a list of steps: 1. Select template, 2. Load metadata (selected), 3. Load sections, and 4. Finish. The second step is selected. There are buttons for 'Load from config file...' and 'Save as config file...'. A table lists metadata properties and their values for the language 'en'. Below the table, there are checkboxes for 'Load metadata from the ontology URI or file' (checked) and 'Load metadata from default config file'. There is also an 'add Language...' button and a 'Use Licensius WS' checkbox. At the bottom, there are '< Back', 'Next >', and 'Cancel' buttons.

Property	Value
abstract	
ontology title	Oscars Ontology
ontology name	Oscars Ontology
ontology description	
ontology introduction	
ontology prefix	[Ontology NS Prefix]
ontology ns URI	http://purl.org/oscar/ontology#
creation date	
modified date	
this version URI	
latest version URI	http://purl.org/oscar/ontology#
previous version URI	
ontology revision	1.0.0

6. En esta ventana podemos añadir lo que no se haya añadido automáticamente del .ttl aunque en nuestro caso al intentarlo, saltaba un error al final del todo.



7. Le damos a generate y si todo ha ido bien, se generará la carpeta en la ubicación que hemos elegido en el primer paso.

OnToolology

Accedemos a la página web: <https://ontoology.linkeddata.es/>

La propia página web tiene instrucciones muy claras sobre cómo utilizar la herramienta, con seguirlas paso a paso sería suficiente para realizar esta parte correctamente.

2.6 Otras herramientas.

Para la generación del grafo de conocimiento se ha utilizado OpenRefine junto con la extensión RDF Transform. A continuación se describe el proceso seguido.

En primer lugar se cargó el fichero oscar.csv en OpenRefine creando un nuevo proyecto. Para poder generar el RDF fue necesario instalar manualmente la extensión RDF Transform, descargada desde el repositorio oficial en GitHub. La instalación requirió colocar la carpeta de la extensión en la ruta %appdata%\OpenRefine\extensions, asegurando que la estructura interna fuera correcta (sin carpetas intermedias con el número de versión). Adicionalmente fue necesario deshabilitar la extensión Wikibase para evitar conflictos. Tras reiniciar OpenRefine la extensión quedó operativa.

A continuación se procedió a reconciliar las entidades del dataset con Wikidata. Para la columna nomineeIds, que contiene identificadores IMDB de personas en formato nm

followed by numbers, se utilizó la propiedad P345 de Wikidata reconciliando contra el tipo humano Q5. Para la columna filmId, que contiene identificadores IMDB de películas en formato tt followed by numbers, se aplicó el mismo proceso reconciliando contra el tipo película Q11424. Este paso permite enlazar las entidades del grafo con Linked Open Data, mejorando la interoperabilidad del Knowledge Graph.

Posteriormente se crearon tres columnas nuevas con las URIs de cada entidad mediante expresiones GREL. Para las personas se usó la columna nomineeIds como base generando URIs con el prefijo `https://w3id.org/oscar/person/`, para las películas se usó filmId con el prefijo `https://w3id.org/oscar/film/` y para las nominaciones se usó nomId con el prefijo `https://w3id.org/oscar/nomination/`. Estas columnas se denominaron uri_person, uri_film y uri_nomination respectivamente.

Una vez creadas las URIs se configuró el esquema RDF mediante la opción Edit RDF Transform. Se definieron tres bloques principales correspondientes a las tres entidades principales de la ontología. El bloque de Person tiene como sujeto uri_person e incluye propiedades como foaf:givenName, foaf:familyName, schema:birthDate, schema:birthPlace, oscar:hasEthnicity, oscar:hasReligion y oscar:hasSexualOrientation. El bloque de Movie tiene como sujeto uri_film con la propiedad schema:name. El bloque de Nomination tiene como sujeto uri_nomination e incluye oscar:year, oscar:isWinner, oscar:category, oscar:nominationName y oscar:characterName, además de las propiedades oscar:nominatedPerson y oscar:forFilm que enlazan como IRI con uri_person y uri_film respectivamente. Se declararon los prefijos oscar, foaf y schema en el editor antes de guardar el esquema.

Finalmente el grafo se exportó en formato Turtle usando la opción Pretty export, obteniendo el fichero oscar-knowledge-graph.ttl con todas las instancias generadas a partir de las filas del csv.

2.7 Comentarios adicionales.

En la parte del análisis con OOPS! se han utilizado herramientas adicionales como conversores de .ttl a .xml y viceversa para garantizar que la información de la ontología no se viera alterada en ningún momento.

En lo que respecta a la generación del grafo de conocimiento, se ha utilizado OpenRefine con la extensión RDF Transform para transformar el dataset oscar.csv en tripletas RDF siguiendo la estructura de la ontología desarrollada. La reconciliación de entidades con Wikidata mediante los identificadores IMDB ha permitido además enriquecer el grafo conectándolo con datos enlazados externos, contribuyendo así a los principios FAIR de interoperabilidad y reusabilidad.

3. Conclusiones

En esta práctica hemos definido un ORSD para el que hemos elaborado una ontología reusando terminología de otras ontologías disponibles en la web, tomado un conjunto de dos datasets que hemos limpiado, integrado y generado el correspondiente grafo de conocimiento. Por otra parte se ha validado la ontología con Oops!, generado la documentación con Widoco y publicado la ontología con OnToology. Además se han creado los shapes SHACL para añadir restricciones sobre los datos. Con todo ello hemos entendido el proceso que conlleva desarrollar un proyecto para crear una ontología sobre un dominio de datos siguiendo los principios FAIR.